



## Metodología

He utilizado una metodología de Machine Learning usando modelos basados en arboles (gradient boosting) para predecir la variable de salida. Este tipo de modelos suele funcionar bien con datos tabulares que asumen que cada observacion es independiente de las demas. Para modelar la temporalidad de los datos, lo usual es valerse de realizar transformaciones que representen informacion de una variable en una ventana de tiempo (como lag, rolling).

Como mi principal interes estaba en modelar usando procesado de lenguaje natural, he decidido entrenar solo usando la serie de datos de entrada desde 2015 hasta 2019 (para así incorporar los datos de tweets en cada día). La meta era obtener una serie de features que contengan informacion relevante del texto de cada tweet y que el modelo aprenda la relacion entre el precio de cierre del IBEX35 y esto.

Para eso he usado la libreria [Spacy](#) de python. Primero eliminando stopwords y lematizando para dejar solo palabras relevantes y luego obteniendo los [word embeddings](#) de los tweets de cada día. Los word embeddings pueden ser usados directamente como variables pero como el numero de dimensiones de los word embeddings dados por Spacy es alto (300 features), he usado Principal Component Analysis (PCA) sobre ellos para dejar solo 10 variables (componentes) que expliquen estos embeddings.

Finalmente, tambien he decidido añadir dos variables indicando el numero de tweets y el numero de tokens (palabras) que se han tweekeado con el hashtag #Ibex35 en cada día y creado variables lag a cada una de ellas de los ultimos 3 y 7 dias anteriores con el proposito de capturar informacion acerca de eventos donde el IBEX35 se encuentre en tendencia.

## Resultados

Mi entrega final ha sido conseguida con un modelo *lightgbm* (gradient boosting machine) con todas las variables que he contruido por medio de los metodos mencionados arriba. A continuacion presento una tabla con los resultados conseguidos despues de evaluar cada metodo de entrenamiento en un conjunto de evaluacion de 200 dias (de la serie desde 2015):

Metodo	F1 en conjunto de test
<i>lightgbm</i> sin feature engineering (dejando los datos como vienen dados)	0.52
<i>lightgbm</i> con feature engineering (variables temporales + lag y rolling)	0.535
<i>lightgbm</i> con word embeddings	0.542
<i>lightgbm</i> con feature engineering + word embeddings	0.584
<i>lightgbm</i> con feature engineering + word embeddings + variables basadas en numero de tweets y tokens por día	0.63